Earthquake Analytics on Complex Data

วิเคราะห์ข้อมูลแผ่นดินไหวทั่วโลกจาก USGS (M4.5 ขึ้นไป, ปี 2000 ถึงปัจจุบัน)

ปุณณวิชญ์ คล้ายรักษ์ รหัส 6710504115

พีรณัฐ ทัศนวิญญู รหัส 6710504191

ศรัณย์ ชัยกุลเสรีวงค์ รหัส 6710504361

ตุลาคม 2026

Abstract

รายงานนี้วิเคราะห์แคตตาล็อกแผ่นดินไหวขนาด 4.5 ขึ้นไปของ USGS ตั้งแต่ 1 ม.ค. 2000 ถึง 10 ต.ค. 2026 จำนวน 187,547 เหตุการณ์ ข้อมูลชุดนี้ซับซ้อนเพราะเป็นข้อมูลเชิงพื้นที่และเวลา เหตุการณ์ไม่เป็นอิสระต่อกัน (aftershock เกิดเป็นกลุ่ม) ขนาดวัดด้วยหลายสเกล ความลึกเกือบครึ่งเป็นค่าที่ตั้งไว้ล่วงหน้า และข้อมูลถูกแก้ไขย้อนหลังได้ เราเก็บข้อมูลด้วยสคริปต์ดึงแบบ incremental ที่รองรับข้อมูลสด ทำความสะอาดข้อมูล แล้วใช้ 3 เทคนิค (1) ST-DBSCAN จับกลุ่ม aftershock ได้ 3,567 กลุ่ม และจับเหตุการณ์ใหญ่ที่รู้จักได้ครบ 5 จาก 5 (2) Isolation Forest หาช่องตาราง-สัปดาห์ที่ผิดปกติ ได้ precision 0.424 บนชุดทดสอบ ซึ่งสูงกว่าการเดาสุ่ม 106 เท่า (3) การจำแนกแบบข้อมูลไม่สมดุล ทำนายว่าเดือนถัดไปจะมีแผ่นดินไหว M6.5 ขึ้นไปหรือไม่ ได้ PR-AUC 0.041 (16 เท่าของการเดาสุ่ม) และชนะ baseline อย่างมีนัยสำคัญ แต่ยังไม่แม่นพอจะใช้เป็นระบบเตือนภัย

สารบัญ

1 บทนำและความซับซ้อนของข้อมูล **3**
1.1 ข้อมูลนี้ซับซ้อนตรงไหน 3

2 การเก็บข้อมูล (API และข้อมูลสด) **4**
2.1 แหล่งข้อมูล 4
2.2 สคริปต์ดึงข้อมูลแบบ incremental 4

3 การสำรวจข้อมูล (Exploration) **5**

4 การเตรียมข้อมูล (Pre-processing) **6**
4.1 การจัดการเชิงพื้นที่และเวลา 7

5 เทคนิคการวิเคราะห์ **8**
5.1 ST-DBSCAN: จับกลุ่ม aftershock และ swarm 8
5.2 Isolation Forest: หาช่องตาราง-สัปดาห์ที่ผิดปกติ 8
5.3 Imbalanced classification: ทำนายแผ่นดินไหวใหญ่เดือนถัดไป 9

6 การประเมินผลและผลลัพธ์ **10**
6.1 ST-DBSCAN 10
6.2 Isolation Forest 11
6.3 Imbalanced classification 12

7 Live Demo **14**

8 การประยุกต์ใช้ **15**

9 ข้อจำกัดและงานในอนาคต **15**

เอกสารอ้างอิง **16**

A ภาคผนวก: หน้าที่ของสมาชิก **18**

1 บทนำและความซับซ้อนของข้อมูล

แผ่นดินไหวขนาดใหญ่เกิดไม่บ่อยแต่สร้างความเสียหายสูง การเข้าใจว่าแผ่นดินไหวเกิดเป็นกลุ่มอย่างไร ช่วงไหนที่พื้นที่หนึ่งมีกิจกรรมผิดปกติ และพื้นที่ไหนมีความเสี่ยงสูงกว่าที่อื่น มีประโยชน์ต่อการวางแผนรับมือภัยพิบัติ การประกันภัย และการติดตาม aftershock หลังเหตุใหญ่

โครงงานนี้มี 3 คำถามหลัก

1. แผ่นดินไหวรวมกลุ่มกันในพื้นที่และเวลาอย่างไร (clustering)
2. ช่องตาราง-สัปดาห์ไหนมีกิจกรรมผิดปกติ (anomaly detection)
3. จากประวัติของพื้นที่ ทำนายได้ไหมว่าเดือนหน้าจะมีแผ่นดินไหวใหญ่ (imbalanced classification)

1.1 ข้อมูลนี้ซับซ้อนตรงไหน

ลักษณะ	หลักฐานจากข้อมูลของเรา
เชิงพื้นที่และเวลา	ทุกแถวมีพิกัด ความลึก และเวลา ระยะทางต้องคิดบนผิวโลก (haversine) และต้องจัดการรอยต่อที่ลองจิจูด $\pm 180^\circ$
ไม่เป็นอิสระต่อกัน	33.5% ของเหตุการณ์อยู่ในกลุ่ม aftershock หรือ swarm เช่น Tohoku 2011 มี 2,980 เหตุการณ์ในกลุ่มเดียว จึงแบ่ง train/test แบบสุ่มไม่ได้
ไม่สมดุลรุนแรง	แผ่นดินไหว M6.5 ขึ้นไปมีแค่ 0.65% ของเหตุการณ์ ในระดับช่องตาราง-เดือนมีแค่ 0.25%
หางยาว	การกระจายของขนาดเป็นไปตามกฎ Gutenberg–Richter ($b = 1.14$) ช่วง M4.5–5.0 กินไปแล้ว 74.4%
ขนาดวัดหลายสเกล	มี `magType` 19 แบบ ส่วนใหญ่เป็น mb (78.5%) ซึ่งอิ่มตัวที่ขนาดใหญ่ ต่างจาก Mw
ค่าที่ตั้งไว้ล่วงหน้า	46.4% ของความลึกเป็นค่าที่ตั้งไว้ล่วงหน้า (10, 30, 33, 35 km) ไม่ใช่ค่าที่วัดได้จริง
ข้อความอิสระ	ชื่อภูมิภาคมาจากข้อความ `place` ซึ่ง 23.2% ไม่มีจุลภาคให้ตัด
ข้อมูลเปลี่ยนย้อนหลัง	USGS แก้ไขขนาดและตำแหน่งย้อนหลัง และเพิ่มเหตุการณ์เก่าเข้ามาทีหลัง เช่น ในการดึงครั้งหนึ่งมีเหตุการณ์เก่าที่เพิ่งเข้ามา 21 รายการ
ข้อมูลสด	มีเหตุการณ์ใหม่ทุกวัน (ประมาณ 34 เหตุการณ์ต่อวันในช่วงทดลอง)

ตารางที่ 1: ลักษณะที่ทำให้ข้อมูลแผ่นดินไหวเป็น complex data

2 การเก็บข้อมูล (API และข้อมูลสด)

2.1 แหล่งข้อมูล

ข้อมูลมาจาก USGS Earthquake Catalog ผ่าน FDSN Event Web Service [1] ในรูปแบบ CSV เงื่อนไขคือ `minmagnitude=4.5`, `starttime=2000-01-01` และ `eventtype=earthquake` ไฟล์ดิบมี 187,588 แถว 24 คอลัมน์ (22 คอลัมน์จาก USGS และอีก 2 คอลัมน์ที่สคริปต์เพิ่ม) ทุกเหตุการณ์มี `id` ที่ไม่ซ้ำกัน และมีคอลัมน์ `updated` บอกเวลาที่ USGS แก้ไขข้อมูลครั้งล่าสุด

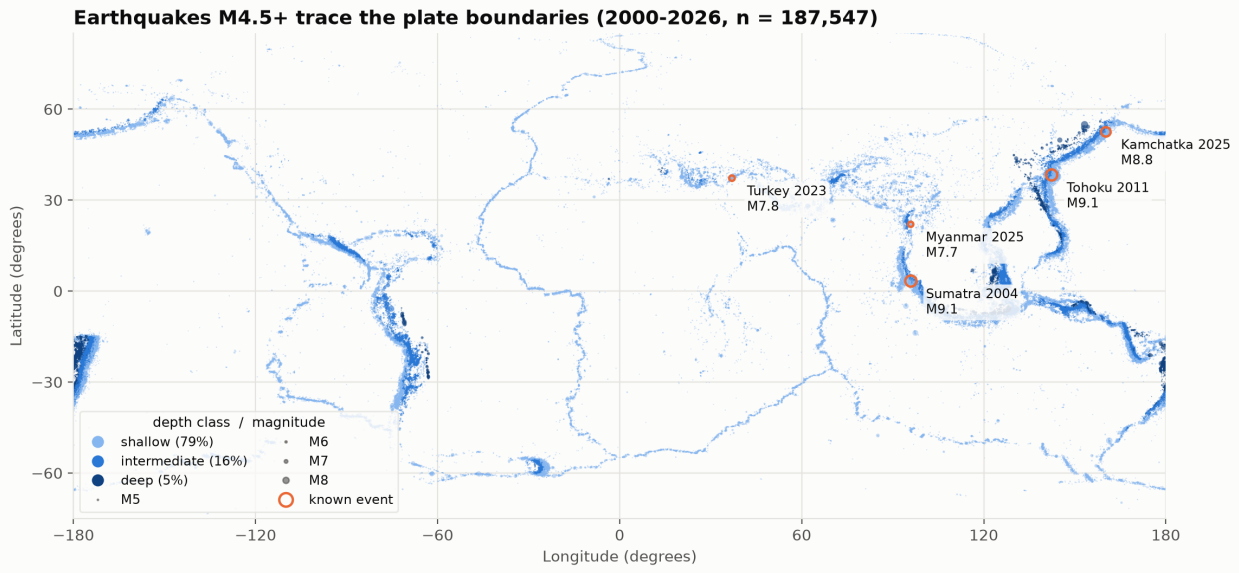
2.2 สคริปต์ดึงข้อมูลแบบ incremental

เราเขียน `scripts/usgs_fetch.py` เป็นสคริปต์เดียวที่ใช้ทั้งดึงข้อมูลย้อนหลังและข้อมูลสด ค่าตั้งต้นทั้งหมดอ่านจาก `scripts/config.py`

1. **ครั้งแรก:** ดึงทั้งหมดตั้งแต่ปี 2000 โดยแบ่งเป็นหน้า หน้าละไม่เกิน 20,000 แถว (ข้อจำกัดของ API) ด้วย `limit` และ `offset`
2. **ครั้งต่อไป:** ขอเฉพาะเหตุการณ์ที่ถูกแก้ไขหลังการดึงครั้งก่อน ด้วย `updatedafter` จึงได้ทั้งเหตุการณ์ใหม่และเหตุการณ์เก่าที่ถูกแก้ไข โดยดึงช่วงขนาดกว้างกว่าเดิม (minmag -0.5) เพื่อไม่พลาดเหตุการณ์ที่ถูกปรับขนาดขึ้นมาเกิน 4.5
3. **เหตุการณ์ที่ถูกลบ:** ขอแยกด้วย `includedeleted=only` แล้วลบออกจากไฟล์ (ถ้าขอรวมในคำขอเดียวกัน API จะ timeout)
4. **รวมข้อมูล:** ใช้ `id` เป็นคีย์ ถ้าซ้ำให้เก็บแถวที่ `updated` ใหม่สุด และบันทึกคอลัมน์ `first_seen_at` กับ `last_fetched_at` เพื่อรู้ว่าแต่ละเหตุการณ์เข้ามาในไฟล์ตอนไหน
5. **ความปลอดภัยของไฟล์:** เขียนลงไฟล์ชั่วคราวก่อนแล้วสลับแทนไฟล์เดิม และเก็บสำรองรายวันไว้ 3 ชุด

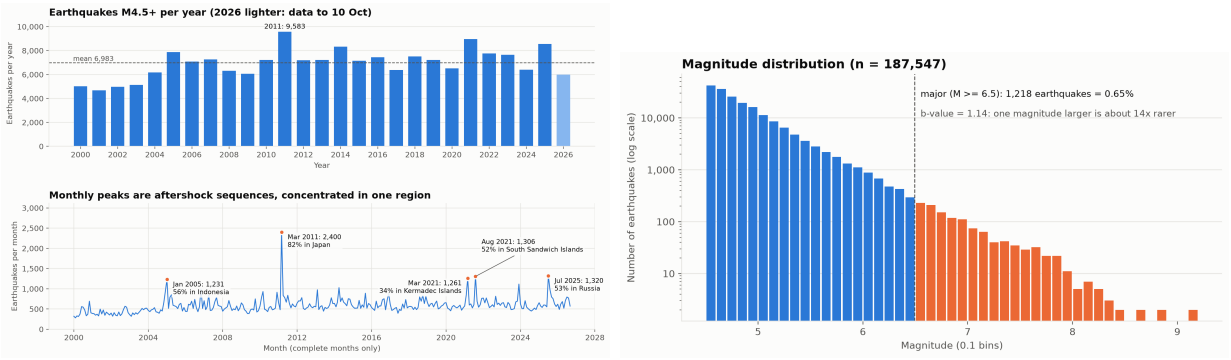
เราเลือกรันสคริปต์**เฉพาะตอนจะใช้ข้อมูล** ไม่เปิดค้างไว้ เพราะ `updatedafter` ทำให้ข้อมูลครบเสมอไม่ว่าจะเว้นช่วงไปนานเท่าไร สิ่งที่เสียไปมีแค่ `first_seen_at` ของช่วงที่ไม่ได้รัน ซึ่งจะเป็นเวลาที่รันครั้งถัดไป

3 การสำรวจข้อมูล (Exploration)

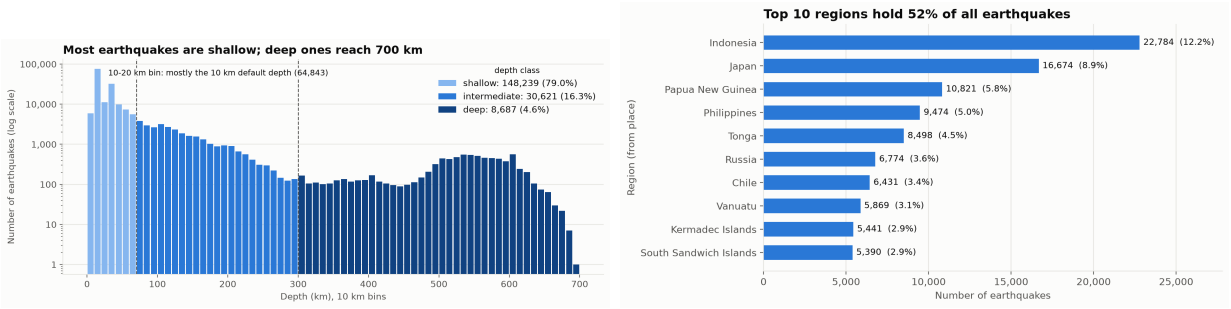


รูปที่ 1: ตำแหน่งแผ่นดินไหว M4.5+ ปี 2000–2026 กระจุกตัวตามแนวรอยต่อแผ่นเปลือกโลก โดยเฉพาะวงแหวนแห่งไฟรอบมหาสมุทรแปซิฟิก

- ปีที่สมบูรณ์ (2000–2025) มีแผ่นดินไหวเฉลี่ย 6,983 ครั้งต่อปี ปีที่มากที่สุดคือ 2011 (9,583 ครั้ง) และน้อยที่สุดคือ 2001 (4,679 ครั้ง)
- เดือนที่มากที่สุดคือ มี.ค. 2011 มี 2,400 ครั้ง โดย 82% เกิดในญี่ปุ่น (aftershock ของ Tohoku M9.1) ยอดสูงอื่น ๆ ก็มาจาก aftershock ของเหตุใหญ่เช่นกัน เช่น ม.ค. 2005 (Sumatra) และ ก.ค. 2025 (Kamchatka)
- ขนาดที่ทำให้แคตตาล็อกสมบูรณ์ (Mc, วิธี maximum curvature $+0.2$ [4, 5]) คือ 4.7 ค่า b ของ Gutenberg–Richter [2] จากวิธี maximum likelihood ของ Aki [3] คือ 1.14 (standard error 0.003)
- แผ่นดินไหว M6.5 ขึ้นไปมี 1,218 ครั้ง ใหญ่ที่สุดคือ M9.1 (Sumatra 2004 และ Tohoku 2011)

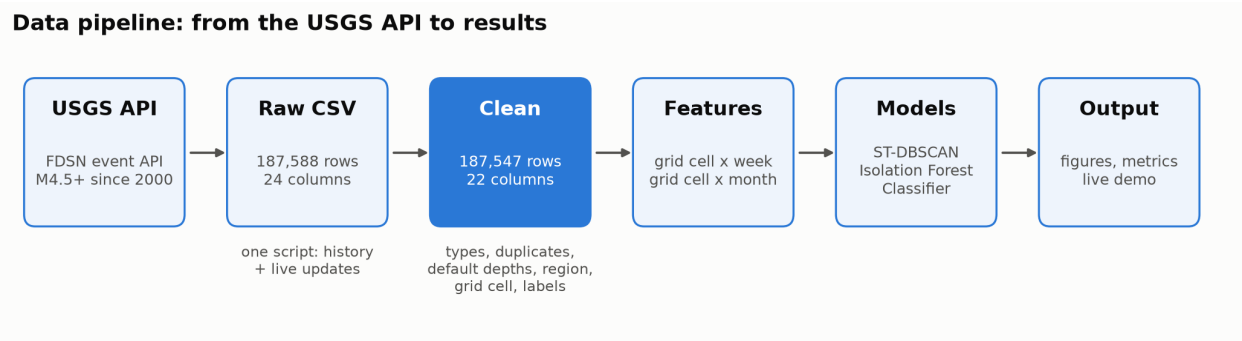


รูปที่ 2: ซ้าย: จำนวนแผ่นดินไหวรายเดือน ยอดแหลมคือช่วง aftershock ของเหตุใหญ่ ขวา: การกระจายของขนาดแบบ log ลดลงเป็นเส้นตรงตามกฎ Gutenberg–Richter



รูปที่ 3: ซ้าย: การกระจายของความลึก มียอดแหลมที่ค่าซึ่งตั้งไว้ล่วงหน้า ขวา: ภูมิภาคที่มีแผ่นดินไหวมากที่สุด

4 การเตรียมข้อมูล (Pre-processing)



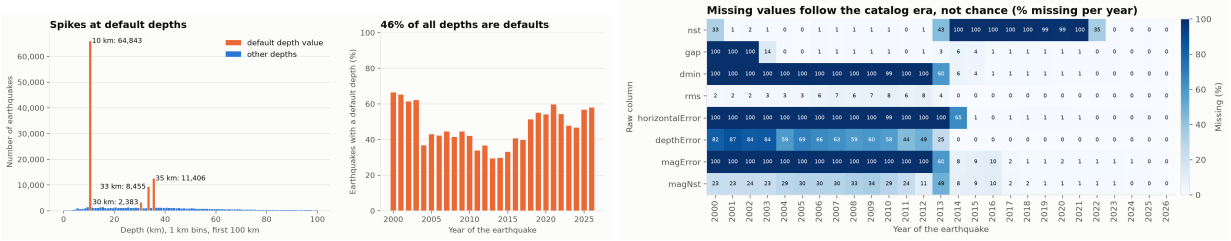
รูปที่ 4: ขั้นตอนการทำความสะอาดข้อมูล จาก 187,588 เหลือ 187,547 แถว

ขั้นตอน	แถวที่เหลือ	ตัดออก
อ่านไฟล์ดิบ แปลงเวลาเป็น UTC	187,588	0
ตัดเหตุการณ์ที่ถูกลบ และที่ไม่ใช่ earthquake	187,588	0
ตัดขนาดต่ำกว่า 4.5 (ถูกปรับขนาดลงทีหลัง)	187,584	4
ตัดแถวที่ค่าหลักหาย	187,584	0
`id` ซ้ำ: เก็บแถวที่ `updated` ใหม่สุด	187,584	0
เหตุการณ์เดียวกันแต่มี 2 `id` (≤ 10 วินาที และ ≤ 10 km): เก็บแถวที่ขนาดใหญ่กว่า	187,547	37
`quakes_clean.csv` **(22 คอลัมน์)**	**187,547**	**41**

ตารางที่ 2: จำนวนแถวในแต่ละขั้นของการทำความสะอาด (`results/step3_summary.csv`)

4.1 การจัดการเชิงพื้นที่และเวลา

- **เวลา:** แปลงเป็น UTC แล้วแยกคอลัมน์ปีและเดือน
- **ความลึกที่ตั้งไว้ล่วงหน้า:** หาค่าความลึกที่มีจำนวนแถวมากกว่าค่ามัธยฐานของค่าข้างเคียงอย่างน้อย 10 เท่า และมีอย่างน้อย 1,000 แถว ได้ 4 ค่า (10, 30, 33, 35 km) รวม 87,087 แถว (46.4%) เราไม่ลบแถวเหล่านี้ แต่ติดธง `depth_fixed` ไว้
- **กลุ่มความลึก:** ตื้น (0–70 km), กลาง (70–300 km), ลึก (300 km ขึ้นไป)
- **ช่องตาราง:** แบ่งโลกเป็นช่องขนาด $5^\circ \times 5^\circ$ (`cell_id`) มี 1,206 ช่องที่มีแผ่นดินไหว
- **ภูมิภาค:** ตัดข้อความหลังจุลภาคตัวสุดท้ายของ `place` ได้ 439 ภูมิภาค
- **ป้ายกำกับ:** `is_major` = ขนาด 6.5 ขึ้นไป (1,218 แถว, 0.65%)



รูปที่ 5: ซ้าย: ค่าความลึกที่ตั้งไว้ล่วงหน้า ขวา: % ค่าว่างของคอลัมน์คุณภาพในแต่ละปี ค่าว่างขึ้นกับยุคของแคตตาล็อก ไม่ได้หายแบบสุ่ม เราจึงไม่ใช้คอลัมน์เหล่านี้เป็น feature

5 เทคนิคการวิเคราะห์

ทุกเทคนิคแบ่งข้อมูลตามเวลา ไม่แบ่งแบบสุ่ม: ฝึกด้วยปี 2000–2019, เลือกค่าด้วยปี 2020–2022, และวัดผลจริงด้วยปี 2023 เป็นต้นไป ซึ่งโมเดลไม่เคยเห็นมาก่อน

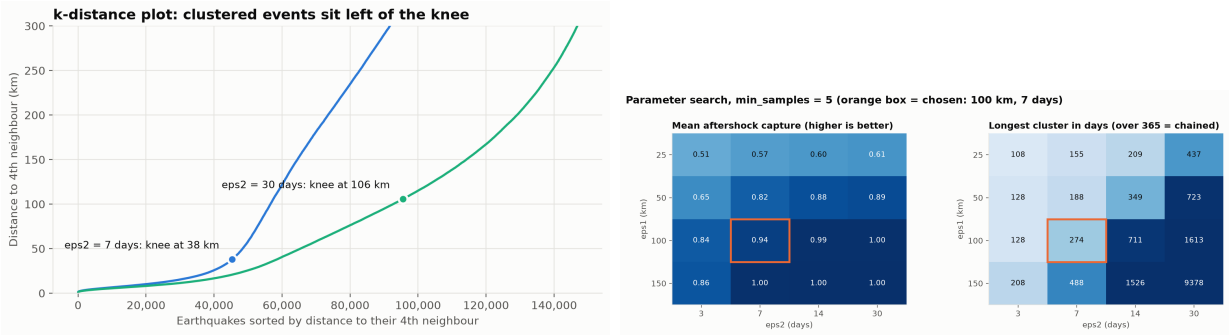
5.1 ST-DBSCAN: จับกลุ่ม aftershock และ swarm

DBSCAN [6] ใช้ระยะทางอย่างเดียว ST-DBSCAN [7] เพิ่มเงื่อนไขเวลา สองเหตุการณ์จะเป็นเพื่อนบ้านกันเมื่ออยู่ห่างกันไม่เกิน ε_1 km **และ**เกิดห่างกันไม่เกิน ε_2 วัน

ไลบรารี `st-dbscan` ติดตั้งบน Python 3.14 ไม่ได้ เราจึงเขียนเอง โดยใช้ KD-tree หาคู่ที่อาจเป็นเพื่อนบ้าน แล้วกรองด้วยระยะ haversine จริงกับช่วงเวลา สร้างเป็นกราฟแบบ sparse แล้วส่งให้ `DBSCAN(metric="precomputed")` ของ scikit-learn [13]

การเลือกค่า: กราฟ k-distance (ระยะไปยังเพื่อนบ้านลำดับที่ 4 ภายใน 7 วัน) มีจุดหักโค้ง (Kneedle [8]) ที่ 38 km แต่ค่านี้เป็นแค่ขอบล่าง เพราะรอยเลื่อนของเหตุใหญ่ยาวหลายร้อยกิโลเมตร (Sumatra 2004 ยาวราว 1,300 km) เราจึงลองทุกชุดของ $\varepsilon_1 \in \{25, 50, 100, 150\}$ km, $\varepsilon_2 \in \{3, 7, 14, 30\}$ วัน, min_samples $\in \{5, 10\}$ แล้วดูว่าจับ aftershock ของเหตุการณ์ใหญ่ที่รู้จัก 5 เหตุการณ์ได้ดีแค่ไหน โดยไม่ให้กลุ่มลากยาวจนผิดธรรมชาติ ค่าที่เลือกคือ $\varepsilon_1 = 100$ km, $\varepsilon_2 = 7$ วัน, min_samples $= 5$ ที่ 7 วันและ min_samples 5 สัดส่วน aftershock ของ Sumatra ที่จับได้คือ 0.00 ที่ 25 km, 0.86 ที่ 50 km และ 0.98 ที่ 100 km ส่วนที่ 150 km กลุ่มเริ่มเชื่อมต่อกันยาวถึง 488 วัน

แต่ละกลุ่มถูกแบ่งเป็น **aftershock sequence** (เหตุการณ์ที่เกิดก่อน mainshock ไม่เกิน 20%) หรือ **swarm** (เกิน 20%)



รูปที่ 6: ซ้าย: กราฟ k-distance ขวา: ผลการลองค่า $\varepsilon_1, \varepsilon_2$

5.2 Isolation Forest: หาช่องตาราง-สัปดาห์ที่ผิดปกติ

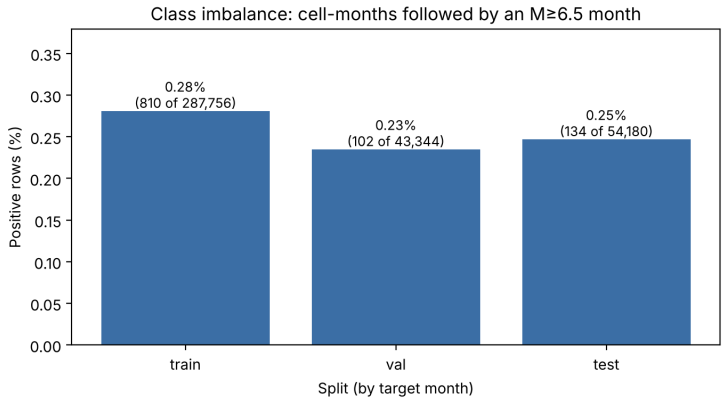
Isolation Forest [10] แยกจุดข้อมูลด้วยการตัดแบบสุ่ม จุดที่ผิดปกติจะถูกแยกออกได้เร็ว (ความลึกของต้นไม้น้อย) หน่วยของข้อมูลคือ **ช่องตาราง** $\times$ **สัปดาห์** ที่มีแผ่นดินไหวอย่างน้อย 1

ครั้ง (91,350 แถว) feature ได้แก่ จำนวนเหตุการณ์ (`n_events`), log ของอัตราเทียบกับค่าปกติของช่องนั้น (`log_rate_ratio`, ค่าปกติคิดจากปี 2000–2019 เท่านั้น), ความลึกเฉลี่ย, ระยะกระจายจากจุดศูนย์กลาง (`spread_km`) และขนาดเฉลี่ย ใช้ต้นไม้ 300 ต้น

โมเดลนี้เรียนรู้แบบไม่มีป้ายกำกับ แต่เพื่อวัดผลได้ เรากำหนดว่าช่อง-สัปดาห์ที่มีแผ่นดินไหว M7.0 ขึ้นไปคือความผิดปกติจริง เพื่อทดสอบ leakage เราฝึก 3 ชุด **A** ใช้ขนาดสูงสุดด้วย (ซึ่งคำนวณจากค่าเดียวกับคำตอบ), **B** ไม่ใช้ขนาดสูงสุด (ผลที่ซื่อตรง และเป็นโมเดลที่ใช้ใน live demo), **C** ไม่ใช้ข้อมูลขนาดเลย ค่า contamination 0.002 เลือกจากชุด validation (F1 สูงสุดของชุด B)

5.3 Imbalanced classification: ทำนายแผ่นดินไหวใหญ่เดือนถัดไป

หน่วยของข้อมูลคือ **ช่องตาราง** $\times$ **เดือน** (1,204 ช่อง $\times$ 320 เดือน) เป้าหมาย $y = 1$ ถ้าเดือนถัดไปมีแผ่นดินไหว M6.5 ขึ้นไปในช่องนั้น feature 15 ตัวใช้ข้อมูลถึงเดือนปัจจุบันเท่านั้น เช่น จำนวนเหตุการณ์ย้อนหลัง 1/3/12 เดือน, จำนวนแผ่นดินไหวใหญ่ 12 เดือน, จำนวนเดือนนับจากแผ่นดินไหวใหญ่ครั้งล่าสุด, สัดส่วนความลึก และกิจกรรมของช่องข้างเคียง



รูปที่ 7: สัดส่วนคลาสบวกในแต่ละช่วง (ประมาณ 0.25%, 1 ต่อ 400)

การป้องกัน leakage (ผ่านทั้ง 8 ข้อ, `results/step7_leakage_checks.csv`): สร้าง feature ใหม่โดยตัดข้อมูลหลังเดือน 2010-06, 2019-12 และ 2023-03 แล้วค่าต้องไม่เปลี่ยน, คำนวณ y ใหม่จากเหตุการณ์จริง, ตรวจว่าป้ายของ train ไม่เลยปี 2019, และไม่ใช้คอลัมน์คุณภาพรายเหตุการณ์ เช่น `magType` หรือ `nst`

โมเดลที่เทียบ:

0. Naive baseline: ทายว่าเป็นบวกถ้าช่องนั้นมีแผ่นดินไหวใหญ่ใน 12 เดือนที่ผ่านมา
1. Logistic Regression ไม่จัดการความไม่สมดุล

2. Logistic Regression + `class_weight="balanced"`
3. LightGBM [12] + class weight
4. LightGBM + SMOTE [11] (ทำบน train เท่านั้น ให้คลาสบวกเป็น 10%)
5. โมเดลที่ PR-AUC บน validation ดีที่สุด + threshold ที่ปรับให้ F1 บน validation สูงสุด

feature แบบนับจำนวนเบ้มาก จึงแปลงด้วย `log1p` และ standardise ก่อนเข้า Logistic Regression ส่วนค่าตั้งของ LightGBM เลือกจาก grid 12 ชุดโดยดู PR-AUC บน validation เท่านั้น ชุด test ใช้แค่ครั้งเดียวตอนท้าย

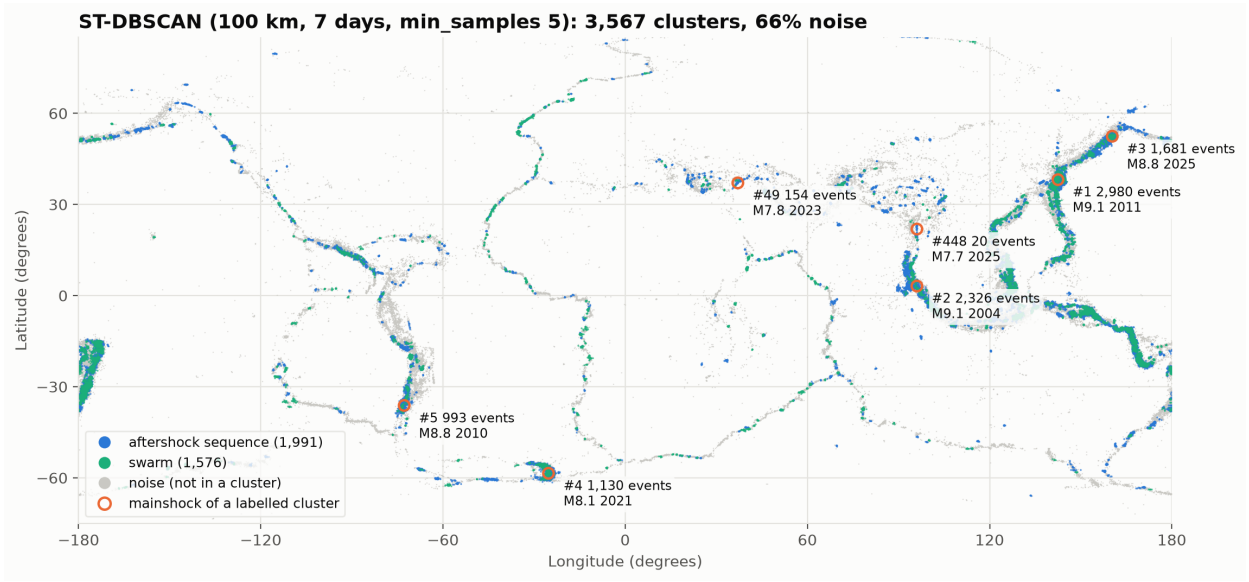
6 การประเมินผลและผลลัพธ์

6.1 ST-DBSCAN

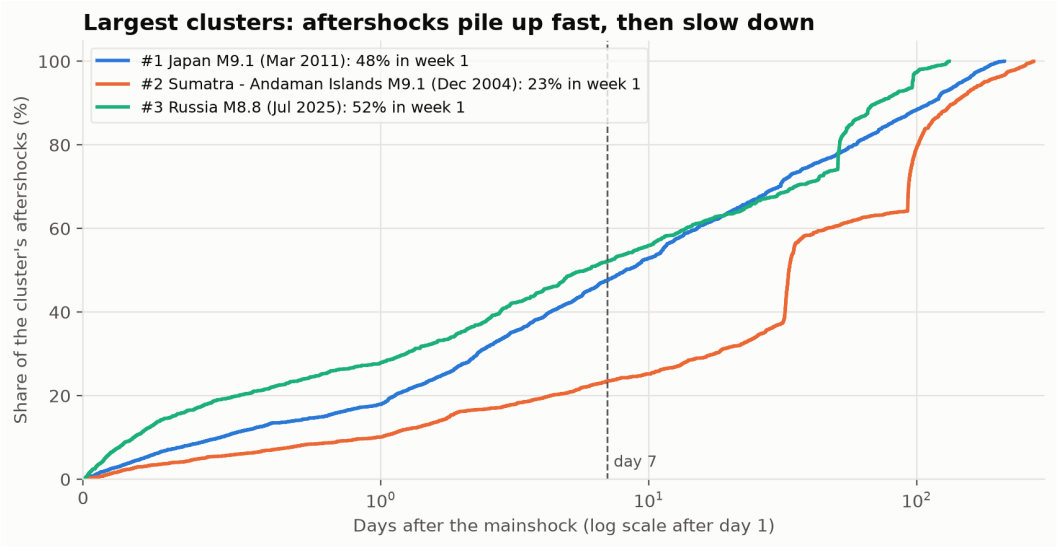
- ได้ 3,567 กลุ่ม (aftershock sequence 1,991, swarm 1,576) มี 1,127 กลุ่มที่มี 10 เหตุการณ์ขึ้นไป
- 66.5% ของเหตุการณ์เป็น noise (ไม่อยู่ในกลุ่มใด) ส่วนแผ่นดินไหวใหญ่อยู่ในกลุ่ม 63.4%
- เหตุการณ์ใหญ่ที่รู้จัก 5 เหตุการณ์อยู่ในกลุ่มครบทั้ง 5 จับ aftershock ได้เฉลี่ย 0.94 (ตารางที่ 3)
- กลุ่มใหญ่ที่สุด 3 อันดับคือ Tohoku 2011 (2,980 เหตุการณ์, 215 วัน), Sumatra 2004 (2,326, 274 วัน) และ Kamchatka 2025 (1,681, 142 วัน)

เหตุการณ์	ขนาด	อันดับกลุ่ม	เหตุการณ์ในกลุ่ม	สัดส่วนที่จับได้
Sumatra 2004	9.1	2	2,326	0.98
Tohoku 2011	9.1	1	2,980	1.00
Turkey 2023	7.8	49	154	0.91
Myanmar 2025	7.7	448	20	0.82
Kamchatka 2025	8.8	3	1,681	1.00

ตารางที่ 3: ตรวจกลุ่มกับเหตุการณ์จริง สัดส่วนที่จับได้ = aftershock ใน 30 วันและ 300 km ที่อยู่ในกลุ่มเดียวกับ mainshock (`results/step5_known_events_check.csv`)



รูปที่ 8: แผนที่กลุ่มจาก ST-DBSCAN สีน้ำเงิน = aftershock sequence, สีเขียว = swarm, สีเทา = noise



รูปที่ 9: กลุ่มใหญ่ที่สุด จำนวน aftershock ลดลงตามเวลาตามกฎของ Omori [9]

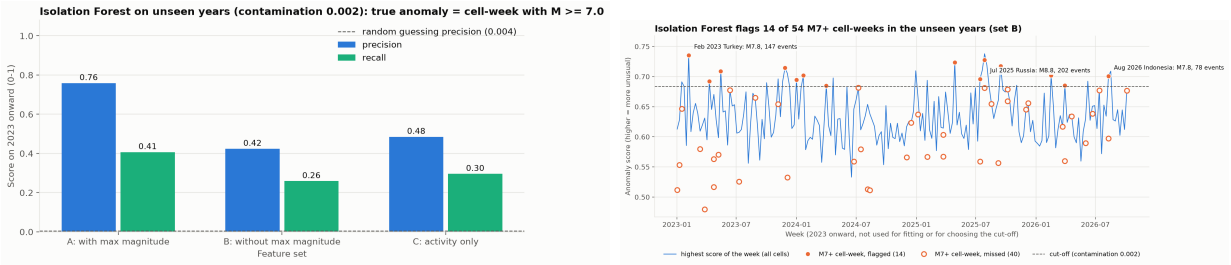
6.2 Isolation Forest

ชุด test (ปี 2023 เป็นต้นไป) มี 13,548 ช่อง-สัปดาห์ เป็นความผิดปกติจริง 54 แถว การเดาสุ่มได้ precision 0.004

ชุด feature	Precision	Recall	F1	PR-AUC	เทียบการเดาสุ่ม
A: มีขนาดสูงสุด (leakage)	0.759	0.407	0.530	0.601	190 เท่า
B: ไม่มีขนาดสูงสุด	**0.424**	**0.259**	**0.322**	**0.274**	**106 เท่า**
C: ไม่ใช้ขนาดเลย	0.485	0.296	0.368	0.244	122 เท่า

ตาราง ที่ 4: ผล Isolation Forest บน ชุด test ที่ contamination 0.002 (`results/anomaly_metrics.csv`)

ช่องว่างระหว่างชุด A กับ B คือผลของ leakage: ถ้าใส่ขนาดสูงสุดซึ่งคำนวณจากค่าเดียวกับคำตอบ ผลจะดูดีเกินจริง ชุด B และ C ยังดีกว่าการเดาสุ่มกว่า 100 เท่า แสดงว่ากิจกรรมที่สูงผิดปกติ (จำนวนและอัตราเทียบกับค่าปกติ) สัมพันธ์กับการเกิดแผ่นดินไหวใหญ่จริง แต่ feature คิดจากสัปดาห์เดียวกับเหตุใหญ่ ซึ่งรวม aftershock ของเหตุนั้นด้วย ผลนี้จึงเป็นการ**ตรวจจับ**ไม่ใช่การ**ทำนายล่วงหน้า**



รูปที่ 10: ซ้าย: ผลของ 3 ชุด feature ที่ค่า contamination ต่าง ๆ ขวา: ช่อง-สัปดาห์ที่ถูก flag ตามเวลา

6.3 Imbalanced classification

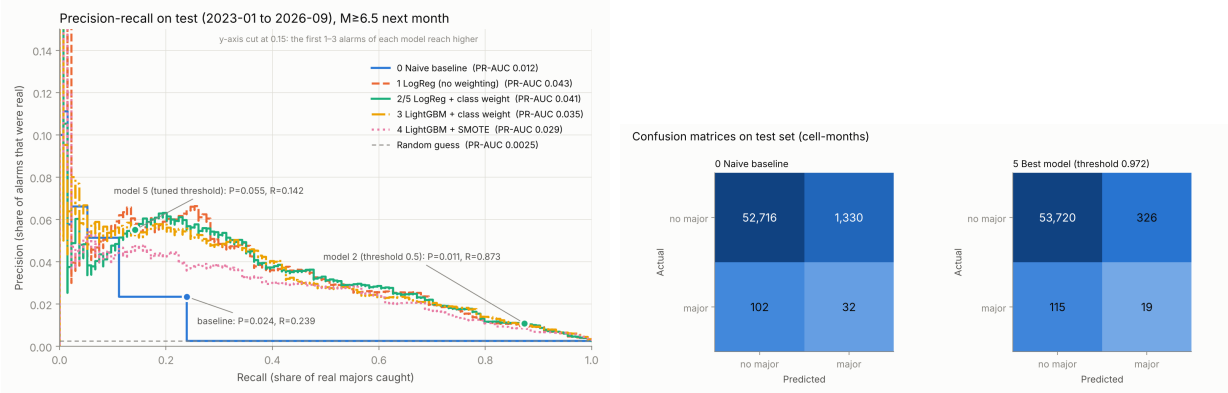
ชุด test มี 54,180 แถว เป็นบวก 134 แถว (0.25%) การเดาสุ่มได้ PR-AUC 0.0025

โมเดล (threshold จาก validation)	Threshold	Precision	Recall	F1	PR-AUC
0. Naive baseline	กฎ	0.023	0.239	0.043	0.012
1. Logistic Regression	0.086	0.048	0.060	0.053	0.043
2/5. Logistic Regression + class weight	**0.972**	**0.055**	**0.142**	**0.079**	**0.041**
3. LightGBM + class weight	0.952	0.054	0.090	0.067	0.035
4. LightGBM + SMOTE	0.544	0.043	0.119	0.063	0.029

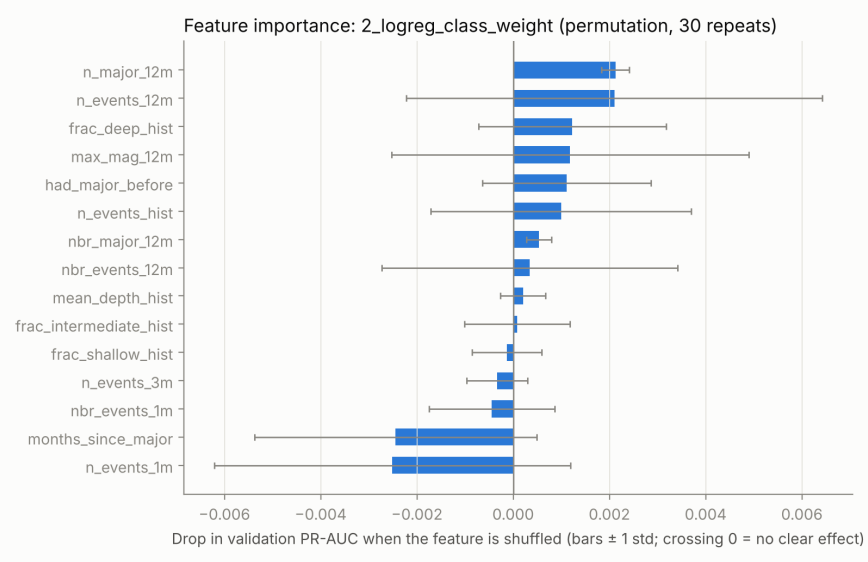
ตาราง ที่ 5: ผล บน ชุด test เมื่อ ทุก โมเดล ได้ threshold ที่ ปรับ บน validation (`results/step8_tuned_threshold_comparison.csv`, `classification_metrics.csv`)

- **Accuracy ใช้ไม่ได้:** Logistic Regression ที่ threshold 0.5 ไม่จัดการความไม่สมดุลได้ accuracy 99.75% แต่จับแผ่นดินไหวใหญ่ได้ 0 จาก 134 เราจึงใช้ precision, recall, F1 และ PR-AUC แทน [14]

- **โมเดลที่ดีที่สุด** คือ Logistic Regression + class weight ที่ threshold 0.972 ได้ precision 0.055, recall 0.142, F1 0.079, PR-AUC 0.041 (16 เท่าของการเดาสุ่ม)
- **ชนะ baseline อย่างมีนัยสำคัญ:** bootstrap 2,000 รอบ (สุ่มทีละเดือนทั้งเดือน) ได้ F1 ดีกว่า $+0.037$ (95% CI $+0.013$ ถึง $+0.061$) และ PR-AUC ดีกว่า $+0.029$ (95% CI $+0.010$ ถึง $+0.052$)
- **ยังไม่ใช่ระบบเตือนภัย:** มี false alarm 326 จาก 345 ครั้งที่เตือน และพลาด 115 จาก 134 เหตุการณ์
- **LightGBM ไม่ช่วย:** โมเดลที่ซับซ้อนกว่าไม่ชนะ เพราะสัญญาณอ่อนและมีตัวอย่างบวกใน validation แค่ 102 ตัว
- **Feature ที่มีผลชัด** คือ `n_major_12m` และ `nbr_major_12m` คือกิจกรรมแผ่นดินไหวใหญ่ล่าสุดในช่องนั้นและช่องข้างเคียง



รูปที่ 11: ซ้าย: precision-recall curve บนชุด test เส้นประคือการเดาสุ่ม ขวา: confusion matrix ของ baseline และโมเดลที่ดีที่สุด



รูปที่ 12: Permutation importance บน validation (PR-AUC ที่ลดลงเมื่อสลับค่า feature)

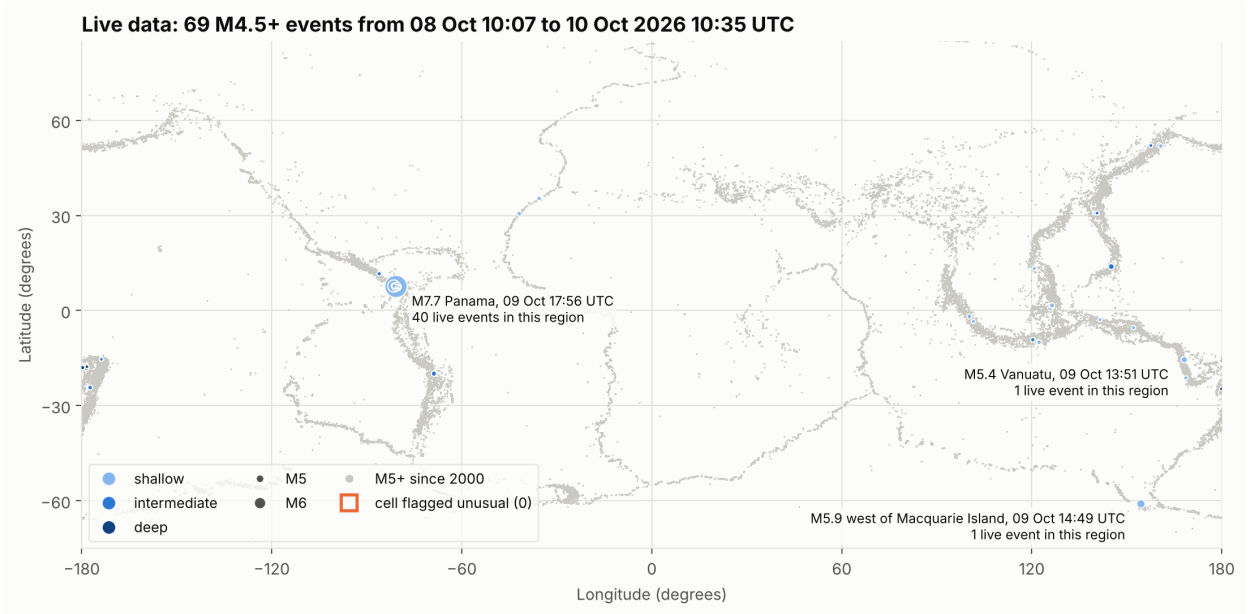
7 Live Demo

เพื่อจำลองข้อมูลสด เรากำหนดจุดเริ่มต้นของช่วงสดเป็น 8 ต.ค. 2026 10:00 UTC เหตุการณ์ที่เกิดหลังเวลานี้และถูกพบครั้งแรกหลังเวลานี้ (`first_seen_at`) ถือเป็นข้อมูลสด แล้วรัน `usgs_fetch.py` 2 ครั้ง

เวลาที่ดึง (UTC)	เหตุการณ์สดใหม่	เหตุการณ์เก่าที่เพิ่งเข้ามา	เหตุการณ์เก่าสุดที่เพิ่งเข้ามา
2026-10-08 10:02	0	1	2026-10-08
2026-10-10 12:36	69	21	2026-07-20

ตารางที่ 6: ผลการดึงข้อมูลสด (`results/step10_fetch_runs.csv`)

- ในช่วง 48.5 ชั่วโมง มีเหตุการณ์ใหม่ 69 ครั้ง (34.2 ครั้งต่อวัน) ใน 24 ช่องตาราง ใหญ่สุดคือ M7.7 ที่ปานามา
- การดึงครั้งที่สองได้เหตุการณ์เก่าที่ USGS เพิ่งเพิ่มเข้ามา 21 รายการ เก่าสุดย้อนไปถึง ก.ค. 2026 แสดงว่าแคตตาล็อกเปลี่ยนย้อนหลังจริง และ `updatedafter` เก็บได้ครบ
- เหตุการณ์ใหม่ถูกส่งเข้าโมเดล Isolation Forest (ชุด B) ที่บันทึกไว้จาก Step 6 ช่องสัปดาห์ของ M7.7 ปานามาได้คะแนน 0.677 ต่ำกว่าเกณฑ์ 0.683 จึงไม่ถูก flag เพราะตอนนั้นสัปดาห์ยังไม่จบ จำนวนเหตุการณ์จึงยังไม่ครบ
- แผนที่ replay แบบ interactive อยู่ที่ `figures/step10_live_replay.html`



รูปที่ 13: เหตุการณ์ในช่วงข้อมูลสด 8–10 ต.ค. 2026

8 การประยุกต์ใช้

- **ติดตาม aftershock:** ST-DBSCAN แยกกลุ่ม aftershock ออกจากกิจกรรมปกติ ช่วยประเมินว่าลำดับ aftershock ยังดำเนินอยู่หรือสงบแล้ว
- **Dashboard แบบ real-time:** `usgs_fetch.py` ร่วมกับ Isolation Forest flag ช่องตารางที่มีกิจกรรมสูงผิดปกติทันทีที่มีข้อมูลใหม่
- **จัดลำดับพื้นที่เสี่ยง:** โมเดลจำแนกจัดอันดับช่องตารางได้ดีกว่าการเดาสุ่ม 16 เท่า ใช้ช่วยจัดลำดับการตรวจสอบอาคารหรือการกำหนดเบี้ยประกันภัยได้ แต่ใช้เตือนภัยรายเดือนไม่ได้
- **ตรวจคุณภาพแคตตาล็อก:** การตรวจความลึกที่ตั้งไว้ล่วงหน้าและเหตุการณ์ซ้ำ ใช้เป็นขั้นตอนมาตรฐานก่อนวิเคราะห์ข้อมูลแผ่นดินไหวอื่นได้

9 ข้อจำกัดและงานในอนาคต

- **การทำนายแผ่นดินไหวยากโดยธรรมชาติ:** ผลการจำแนกต่ำ (F1 0.079) ไม่ใช่ความล้มเหลวของวิธี แต่สะท้อนว่าประวัติในอดีตบอกได้แค่ว่าพื้นที่ไหนเสี่ยงกว่า ไม่ได้บอกเวลาที่แน่นอน
- **Leakage:** เราป้องกันด้วยการแบ่งตามเวลา, คำนวณค่าปกติจากช่วง train เท่านั้น, ทำ SMOTE และ scaler บน train เท่านั้น, และทดสอบตัดข้อมูลอนาคต ส่วน Isolation For-

est แสดงให้เห็นว่าถ้าใส่ขนาดสูงสุด precision จะพองจาก 0.424 เป็น 0.759

- **แคตตาล็อกต่ำกว่า M4.5 ไม่สมบูรณ์:** Mc ทั่วโลกคือ 4.7 ข้อมูลช่วง 4.5–4.7 จึงขาดบางส่วน โดยเฉพาะในพื้นที่ที่มีสถานีวัดน้อยและในปีแรก ๆ
- **ขนาดวัดหลายสเกล:** เราใช้ `mag` ตามที่ USGS ให้มาโดยไม่แปลงให้เป็นสเกลเดียวกัน mb ซึ่งเป็นส่วนใหญ่อิ่มตัวที่ขนาดใหญ่
- **ความลึกที่ตั้งไว้ล่วงหน้า:** 46.4% ของความลึกไม่ใช่ค่าจริง feature ที่ใช้ความลึกจึงมีสัญญาณรบกวน
- **ช่องตารางคงที่:** ช่อง 5° ไม่ตรงกับรูปร่างของรอยเลื่อน และพื้นที่จริงของช่องเล็กลงเมื่อเข้าใกล้ขั้วโลก
- **ข้อมูลสดขาดช่วง:** เราไม่ได้รันสคริปต์ตลอดเวลา `first_seen_at` ของช่วงที่ไม่ได้รันจึงเป็นเวลาที่รันครั้งถัดไป ช่วงข้อมูลสดมีแค่ 48.5 ชั่วโมง
- **งานในอนาคต:** แปลงขนาดให้เป็น Mw, ใช้ช่องตารางที่ปรับตามแนวรอยเลื่อน, เพิ่ม feature จากแบบจำลอง ETAS, และรันข้อมูลสดต่อเนื่องเป็นเวลานานขึ้น

เอกสารอ้างอิง

[1] U.S. Geological Survey. *Earthquake Catalog API Documentation (FDSN Event Web Service)*. https://earthquake.usgs.gov/fdsnws/event/1/

[2] Gutenberg, B., & Richter, C. F. (1944). Frequency of earthquakes in California. *Bulletin of the Seismological Society of America*, 34(4), 185–188.

[3] Aki, K. (1965). Maximum likelihood estimate of b in the formula $\log N = a - bM$ and its confidence limits. *Bulletin of the Earthquake Research Institute*, 43, 237–239.

[4] Wiemer, S., & Wyss, M. (2000). Minimum magnitude of completeness in earthquake catalogs: Examples from Alaska, the western United States, and Japan. *Bulletin of the Seismological Society of America*, 90(4), 859–869.

[5] Woessner, J., & Wiemer, S. (2005). Assessing the quality of earthquake catalogues: Estimating the magnitude of completeness and its uncertainty. *Bulletin of the Seismological Society of America*, 95(2), 684–698.

[6] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of KDD-96*, 226–231.

[7] Birant, D., & Kut, A. (2007). ST-DBSCAN: An algorithm for clustering spatial–temporal data. *Data & Knowledge Engineering*, 60(1), 208–221.

[8] Satopää, V., Albrecht, J., Irwin, D., & Raghavan, B. (2011). Finding a "kneedle" in a haystack: Detecting knee points in system behavior. *ICDCS Workshops*, 166–171.

[9] Utsu, T., Ogata, Y., & Matsu'ura, R. S. (1995). The centenary of the Omori formula for a decay law of aftershock activity. *Journal of Physics of the Earth*, 43(1), 1–33.

[10] Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *Proceedings of the 8th IEEE International Conference on Data Mining*, 413–422.

[11] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

[12] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems 30*, 3146–3154.

[13] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[14] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432.

A ภาคผนวก: หน้าที่ของสมาชิก

สมาชิก	งานที่ทำ
ปุณณวิชญ์ คล้ายรักษ์	ทดลองดึงข้อมูลรอบแรก, แก้ปัญหา timeout ของ `usgs_fetch.py`, Step 3 การเตรียมข้อมูล (`02_preprocess.ipynb`), live demo รุ่นแรก
ศรัณย์ ชัยกุลเสรีวงค์	ออกแบบและเขียน `usgs_fetch.py` และ `config.py`, Step 4 EDA, Step 5 ST-DBSCAN, Step 6 Isolation Forest, เอกสารอธิบาย Step 3–6, Step 11 ล็อกผล
พีรณัฐ ทัศนวิญญู	Step 7 ตาราง feature และการตรวจ leakage, Step 8 imbalanced classification และการปรับ LightGBM, Step 9 การประเมินผล, Step 10 live demo

ตารางที่ 7: หน้าที่ของสมาชิก (จาก commit ใน GitHub) ให้สมาชิกตรวจและแก้ให้ตรงก่อนส่ง

โค้ดและผลลัพธ์ทั้งหมด: https://github.com/tls123qq/Earthquake-project
ตัวเลขทุกตัวในรายงานนี้คัดมาจาก `results/step11_final_numbers.md`